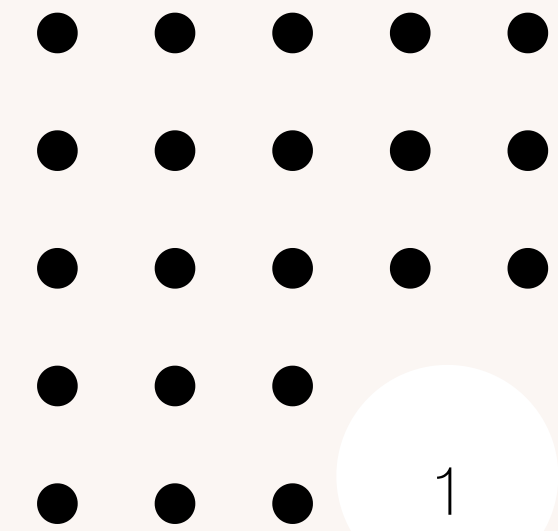
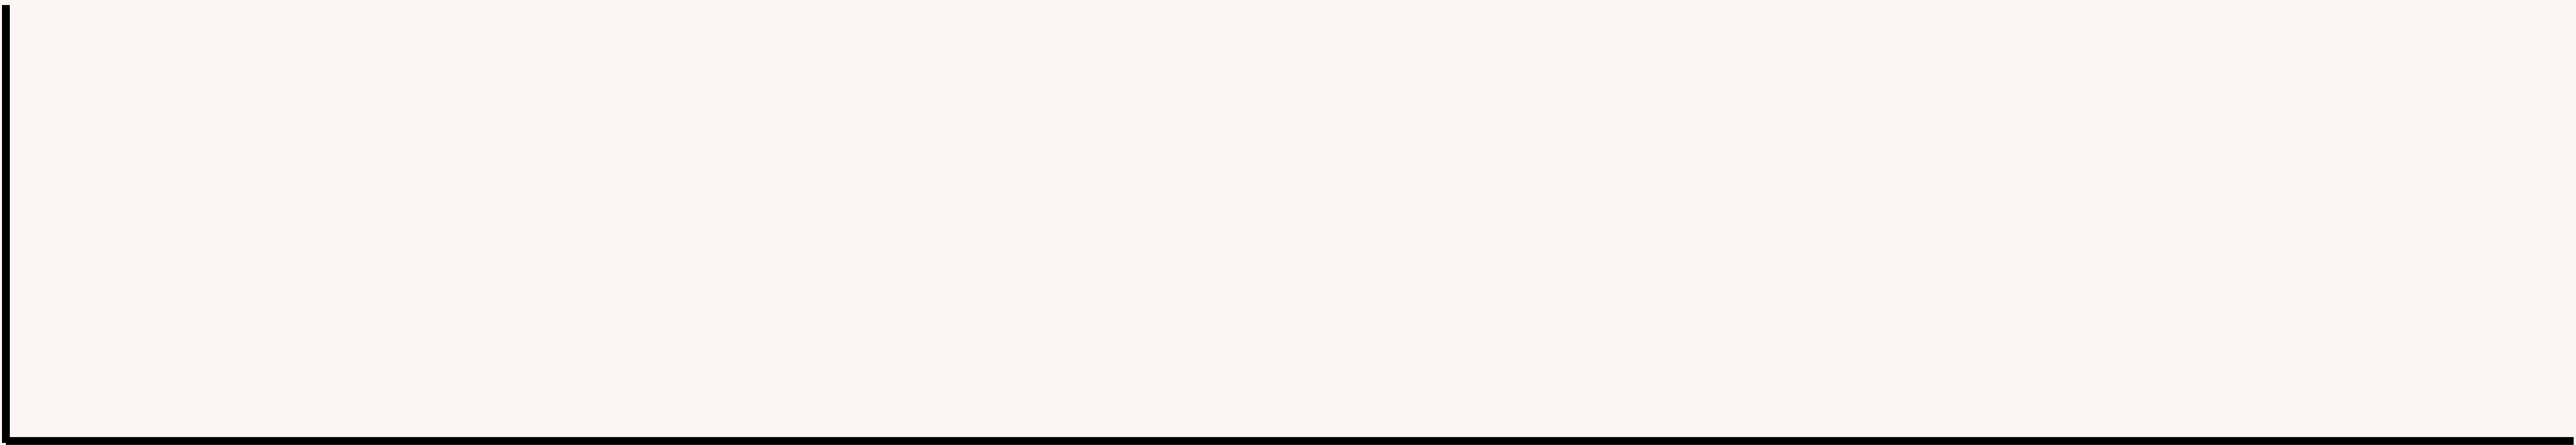


ANÁLISE COMPARATIVA ENTRE UM MODELO K-NN E UM PERCEPTRON SIMPLES




INTEGRANTES DA EQUIPE:

Bruno Marques da Silva-6972	bruno.silva63@ufv.br
Luís Fernando Almeida-8102	luis.almeida1@ufv.br
Marcella Clemente Alves-8759	marcella.alves@ufv.com


Docentes:

Larissa Ferreira Rodrigues Moreira
Leandro Henrique Furtado Pinto Silva




SUMÁRIO

- Introdução
- Objetivo
- Metodologia
- Métricas de Avaliação em Classificação
- Resultados e discussão
- Conclusão




INTRODUÇÃO

- O reconhecimento de padrões é essencial na inteligência artificial, focando na identificação automática de padrões em dados.
- O estudo compara dois modelos: k-NN (simples e eficaz) e Perceptron Simples (capaz de aprender padrões complexos).



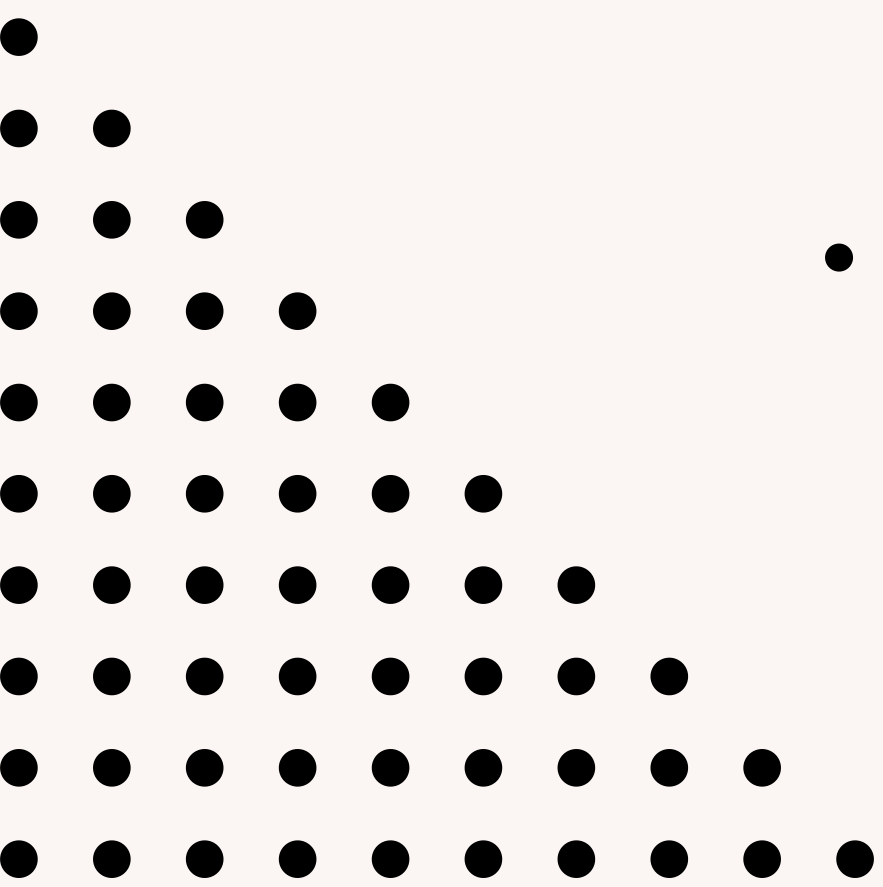
OBJETIVO

- Avaliar o desempenho de ambos os modelos, ajustando parâmetros para melhores resultados.
- Resultados iniciais mostram que k-NN atingiu 70% de acurácia, enquanto Perceptron Simples alcançou 62%.



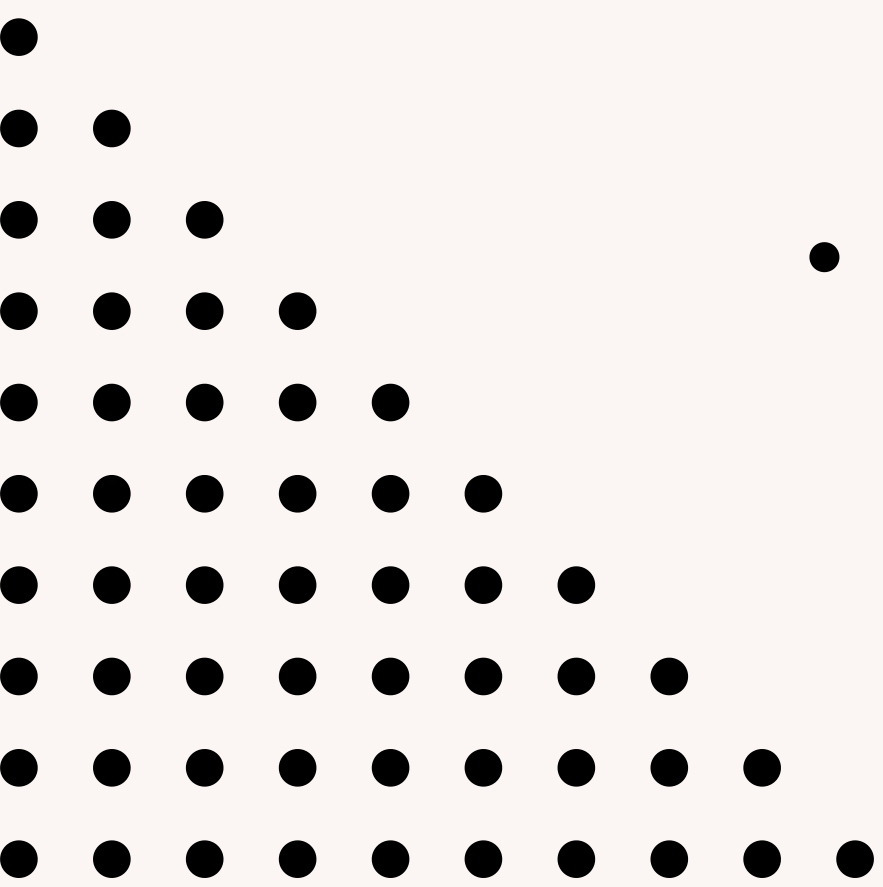


METODOLOGIA

- Dataset:
 - Dados sintéticos com 16 features numéricas e classe binária.
 - Z-Score.
 - Divisão em 80% treinamento, 20% teste.
 - Arquiteturas:
 - k-NN: Simples, baseado em proximidade.
 - Perceptron Simples: Ajuste iterativo de pesos para padrões complexos.
- 



METODOLOGIA

- Projeto dos Experimentos:
 - Normalização dos dados.
 - Variação do k (1 a 100) para encontrar o melhor valor.
 - Métricas de avaliação.
 - Recursos Computacionais:
 - Implementação em Python no Google Colab.
 - Bibliotecas: scikit-learn, pandas, matplotlib e seaborn.
- 



MÉTRICAS DE AVALIAÇÃO EM CLASSIFICAÇÃO

- Precisão (Precision):
 - Definição: Indica a proporção de instâncias positivas corretamente identificadas entre as previstas positivas.
 - Cálculo: $\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$
 - Interpretação: Avalia a confiabilidade do modelo ao prever a classe positiva.
- Recall (Sensibilidade):
 - Definição: Mostra a proporção de instâncias positivas corretamente identificadas entre as reais positivas.
 - Cálculo: $\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$
 - Interpretação: Avalia a capacidade do modelo em capturar todos os casos positivos.

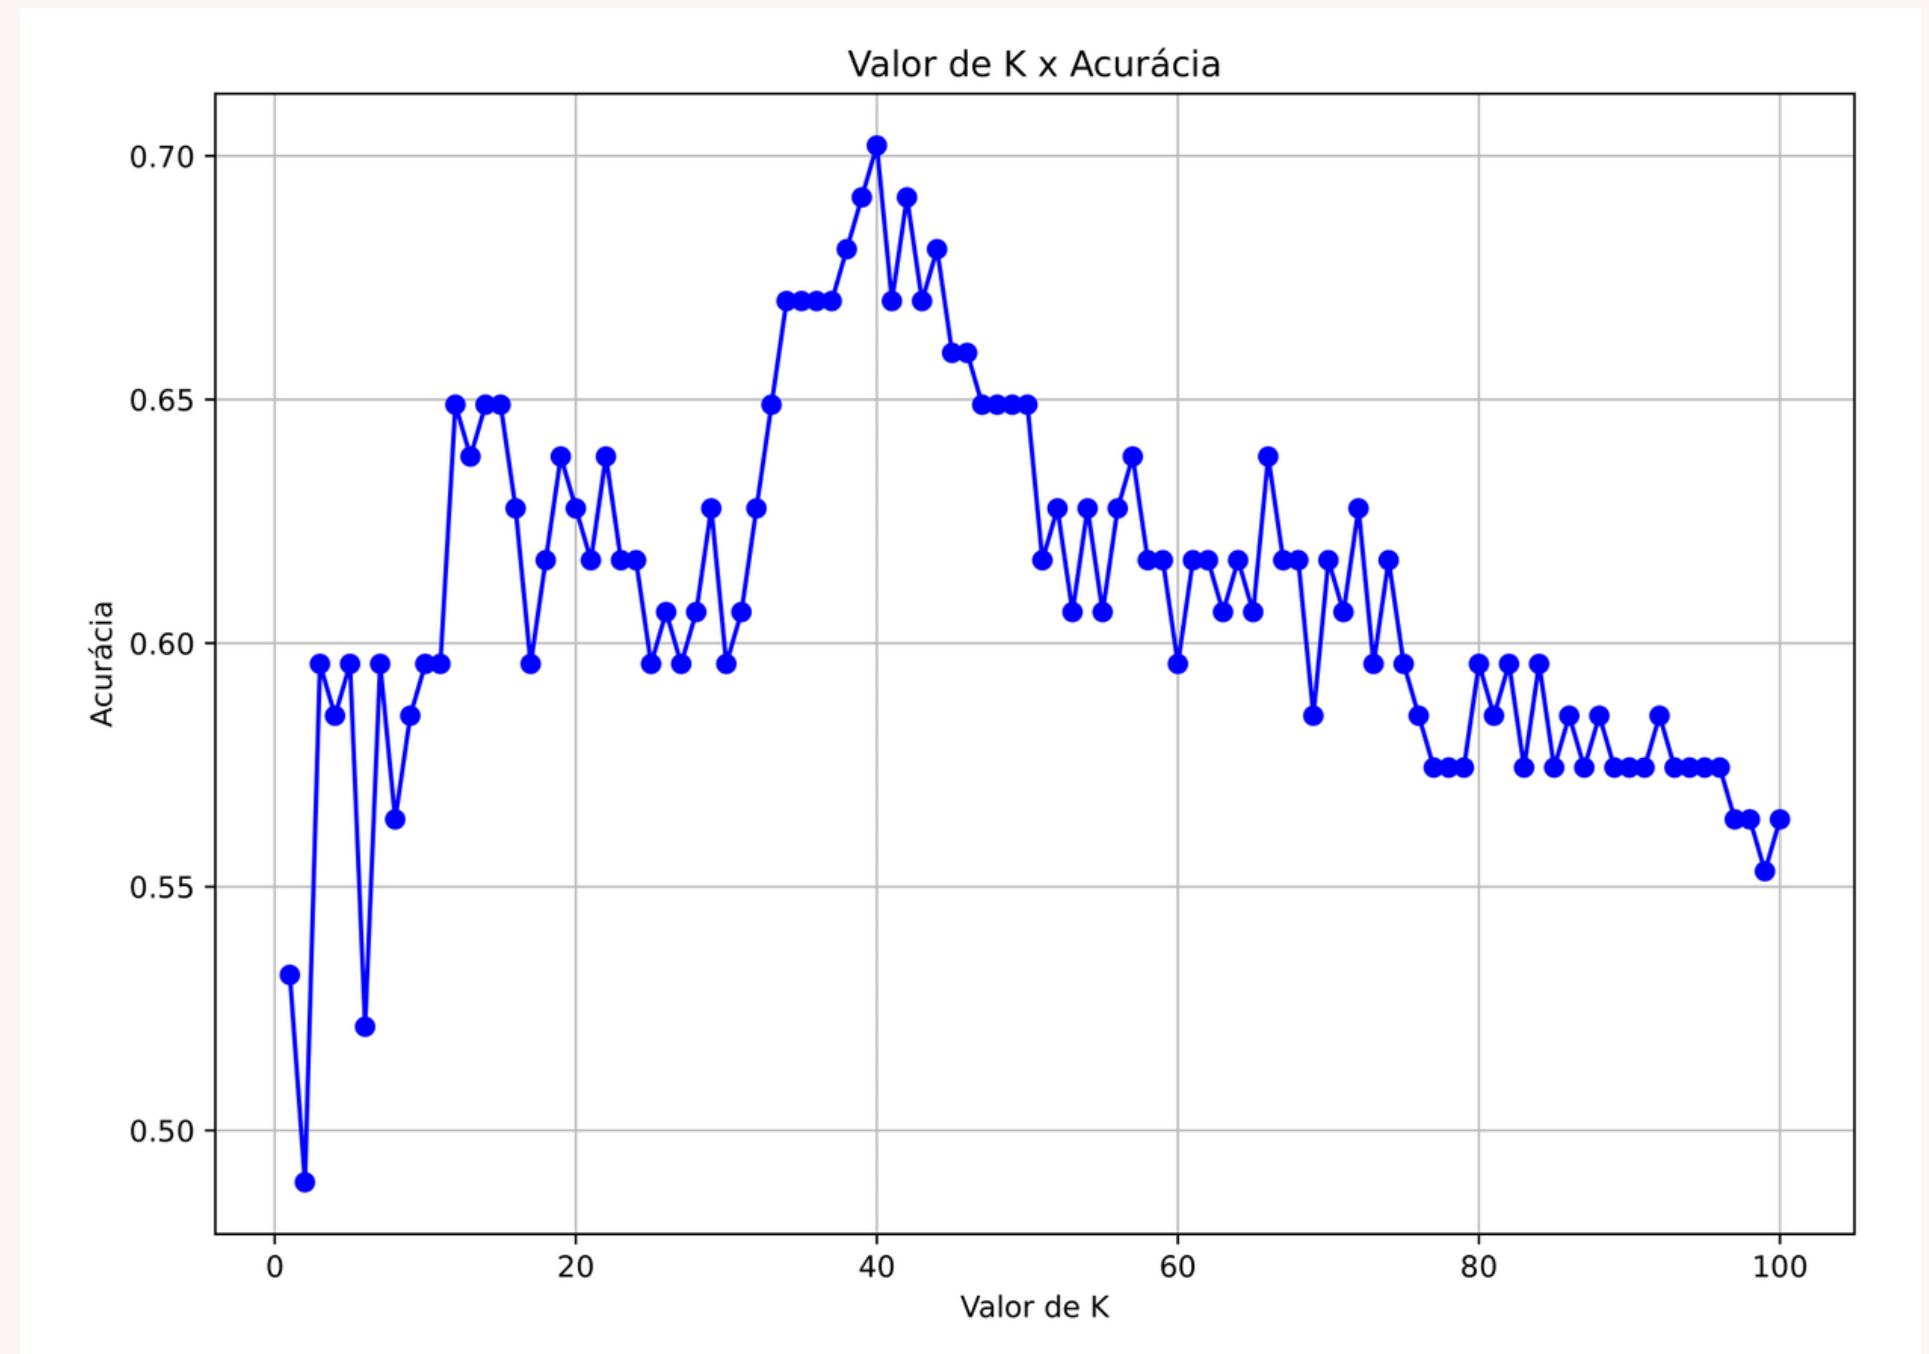


MÉTRICAS DE AVALIAÇÃO EM CLASSIFICAÇÃO

- F1 Score:
 - Definição: Combina precisão e recall em uma métrica única, útil quando há desequilíbrio entre classes.
 - Cálculo: $F1\ Score = 2 * (Precision * Recall) / (Precision + Recall)$
 - Interpretação: Busca equilíbrio entre precisão e recall, útil em situações onde ambos são importantes.


RESULTADOS E DISCUSSÃO

- **k-NN:** Acurácia de 70%, $k = 40$.



RESULTADOS E DISCUSSÃO

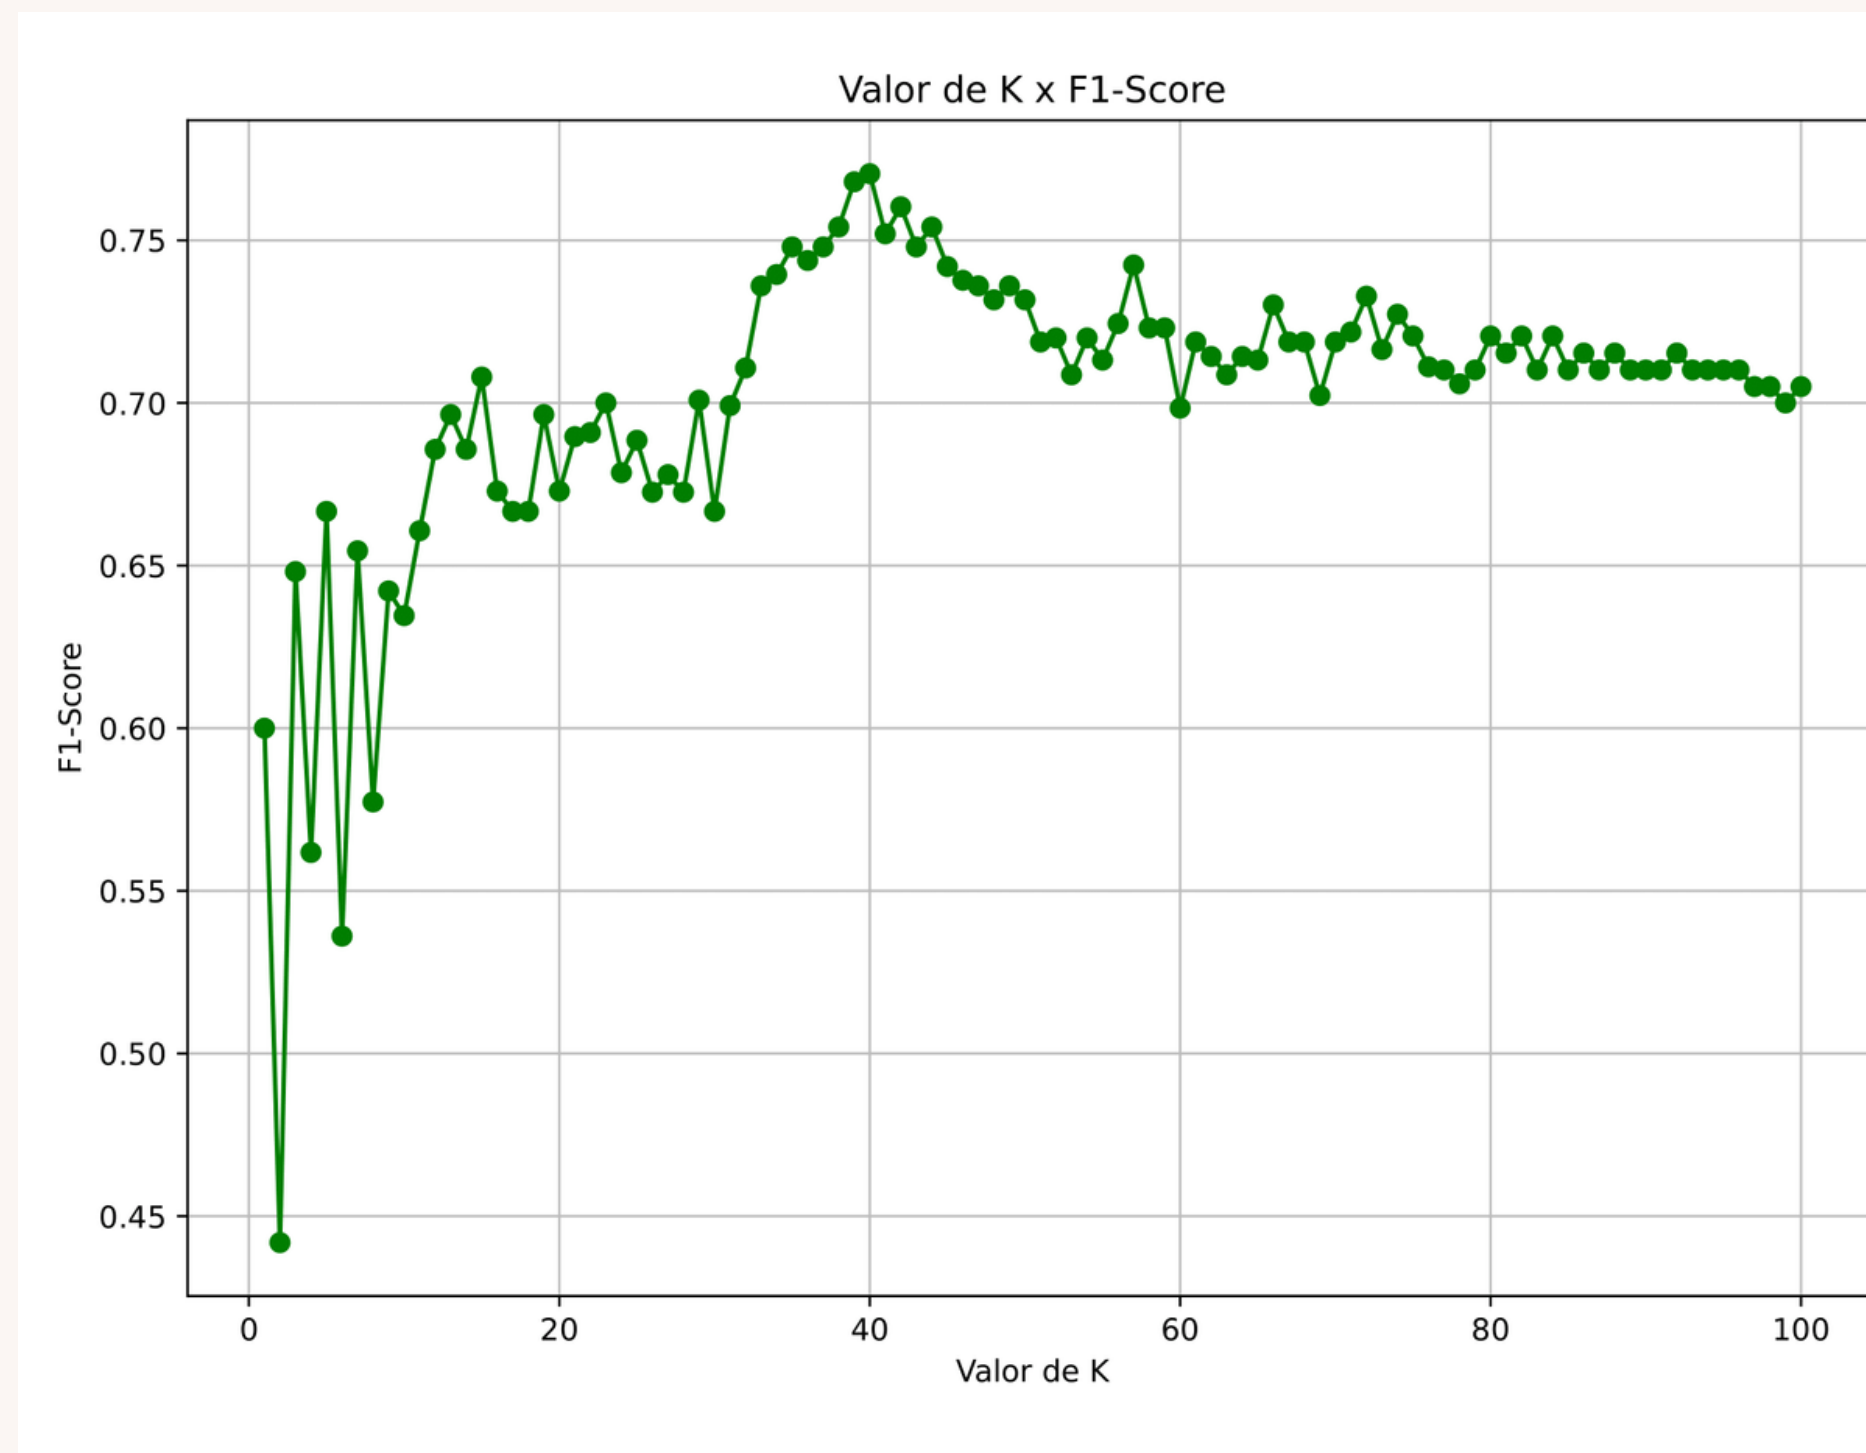
- **k-NN:** Sensibilidade robusta, baixo número falsos negativos.
- **Acurácia = 70%**
- **Precisão = 65%**
- **Recall (Sensibilidade) = 94%**
- **Especificidade = 43%**





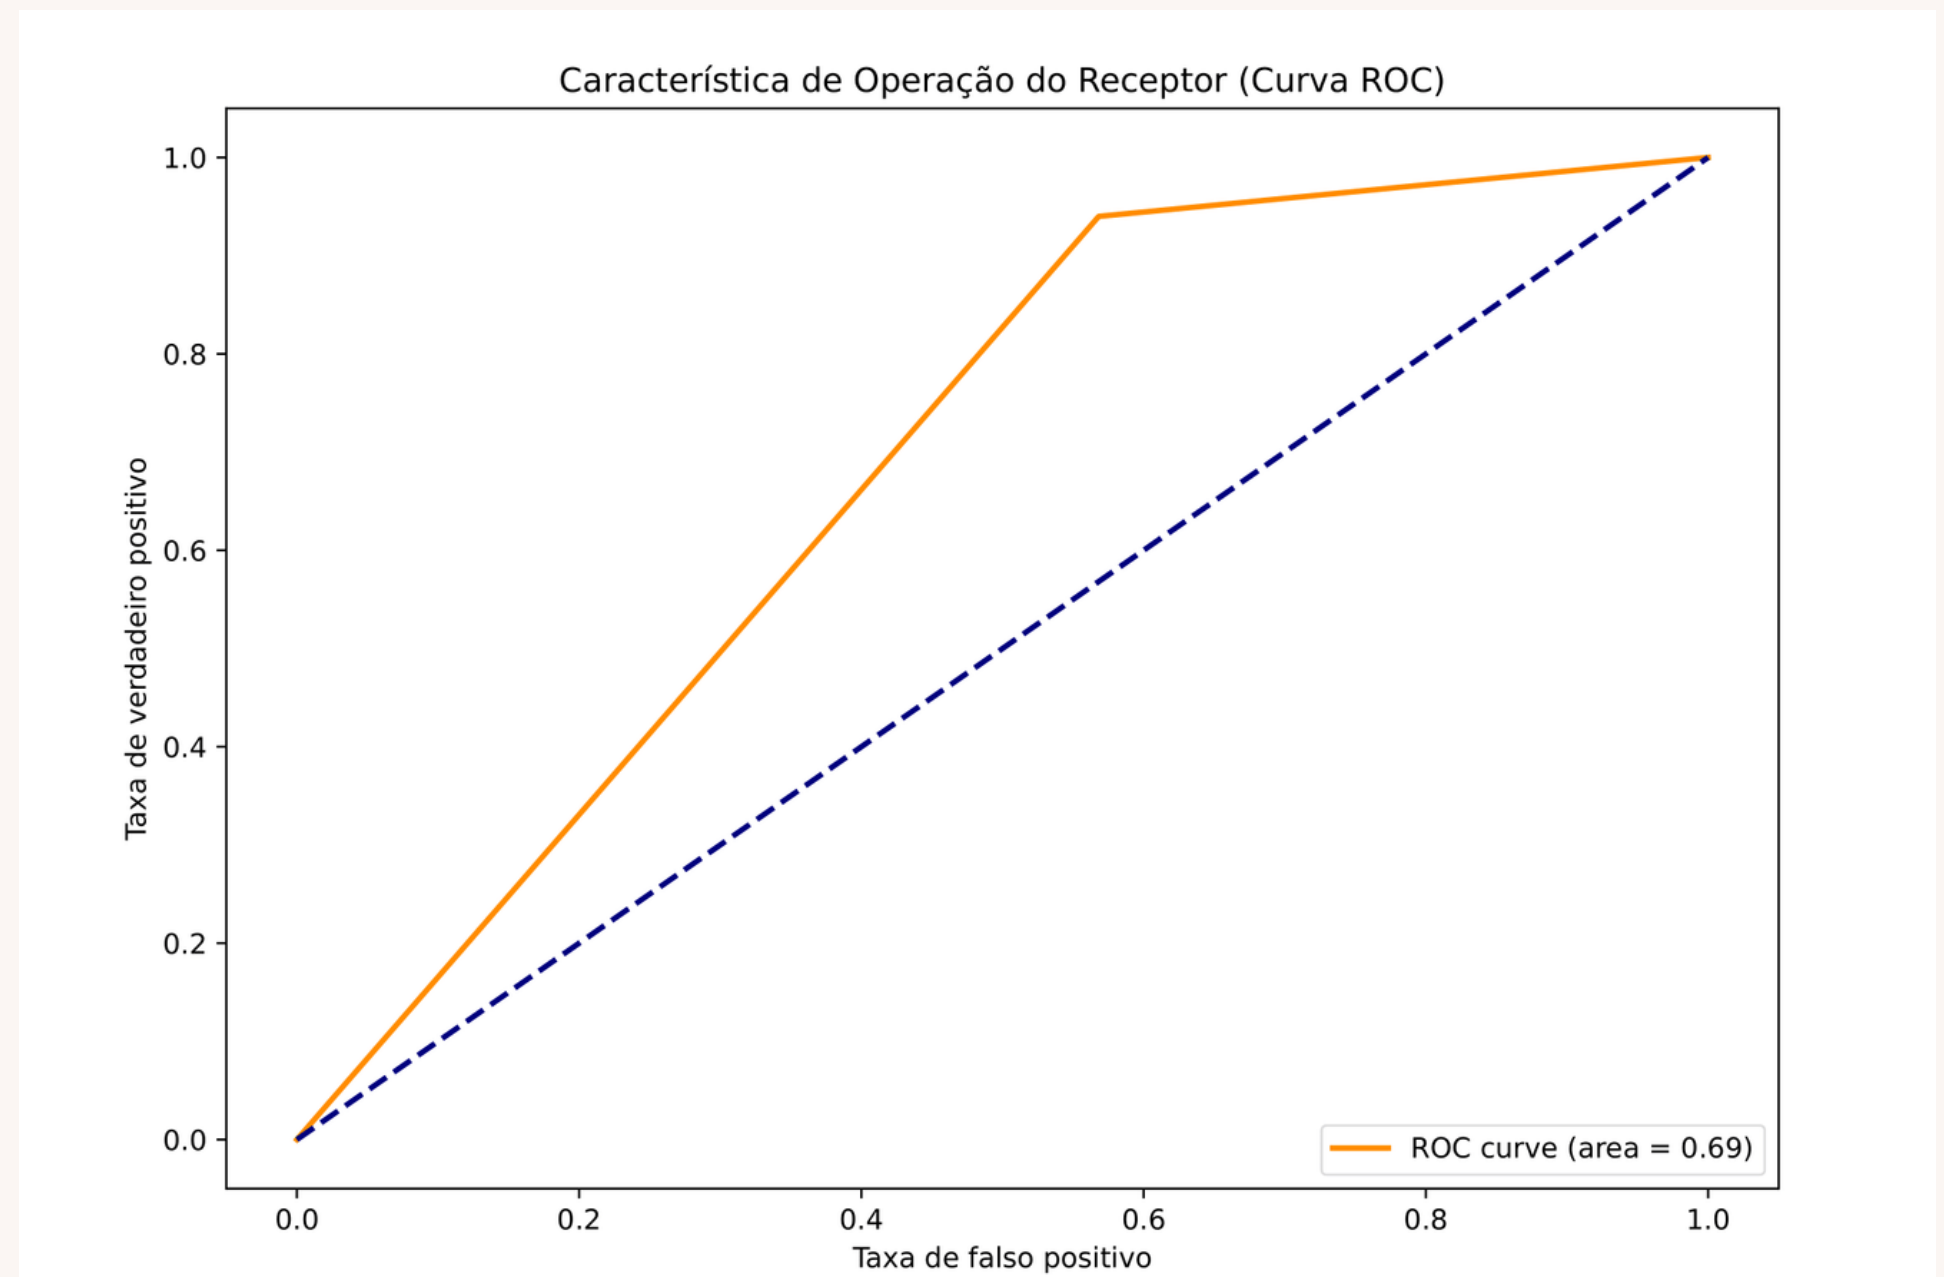
RESULTADOS E DISCUSSÃO

- **F1-Score = 75,2%**




RESULTADOS E DISCUSSÃO

- **Curva ROC:** relação entre a taxa de verdadeiros positivos e a taxa de falsos positivos.



RESULTADOS E DISCUSSÃO

- **Perceptron:** Equilíbrio entre falsos positivos e falsos negativos.
- **Acurácia** = 62%
- **Precisão** = 63%
- **Recall (Sensibilidade)** = 66%
- **Especificidade** = 57%





CONCLUSÃO


- Diferenças significativas entre os modelos.
- Escolha dependente do contexto: k-NN sensível a eventos positivos, Perceptron Simples equilibrado.
- Contribuições para escolha de modelo em diferentes cenários.

• • • • •
• • • • •
• • • • •
• • • • •
• • • • •
• • • • •
• • • • •
• • • • •

Obrigado(a) pela atenção!


Dúvidas?





Referências

1. M. A. Ponti and G. B. P. da Costa, “Como funciona o deep learning,” CoRR, vol. abs/1806.07908, 2018. [Online]. Available: <http://arxiv.org/abs/1806.07908>
2. E. Alpaydin, Introduction to Machine Learning, fourth edition, ser. Adaptive Computation and Machine Learning series. MIT Press, 2020. [Online]. Available: <https://books.google.com.br/books?id=tZnSDwAAQBAJ>
3. T. Cover and P. Hart, “Nearest neighbor pattern classification,” IEEE transactions on information theory, vol. 13, no. 1, pp. 21–27, 1967.
4. H. Bhavsar and A. Ganatra, “A comparative study of training algorithms for supervised machine learning,” International Journal of Soft Computing and Engineering (IJSCE), vol. 2, no. 4, pp. 2231–2307, 2012.



5. H.-D. Block, “The perceptron: A model for brain functioning. i,” *Reviews of Modern Physics*, vol. 34, no. 1, p. 123, 1962.
6. M. Sokolova, N. Japkowicz, and S. Szpakowicz, “Beyond accuracy, f-score and roc: a family of discriminant measures for performance evaluation,” in *Australasian joint conference on artificial intelligence*. Springer, 2006, pp. 1015–1021.
7. Z. H. Hoo, J. Candlish, and D. Teare, “What is an roc curve?” 2017.